5회차 · CDC / Iceberg 프로젝트 스터디

현재 상태에서 믿을 수 있는 지표로

dbt · Silver core(fact·dim) · Gold 지표 · 데이터 테스트

Silver에 공통 fact·dim을 만들고 Gold에서 정산 지표를 내보냅니다

흐름을 먼저 알고 설계한다

8회 단계적 진행 로드맵

STEP 1 — 1회차

개념 & 환경 구성

[핵심 학습]

- OT · 왜 CDC+Lakehouse인가
- CDC/Iceberg 내부 구조와 장단점
- 실습 환경 구성 및 공통 예제 흐름 체험

[프로젝트 진행 방식]

공통 예제 (orders·payments·refunds)로 전체 구조 파악

STEP 2 — 2~3회차

수집·적재 흐름 체득

[핵심 학습]

- 2회차: PostgreSQL → Debezium → Kafka 변경 수집
- 3회차: Flink → Iceberg Bronze 적재·지연 측정

[프로젝트 진행 방식]

공통 예제로 c/u/d·체크포인트·커밋을 직접 다룬 뒤, 3회차에 내 개인 프로젝트 도메인·테이블 설계 확정

STEP 3 — 4~6회차

내 프로젝트 본격 구현

[핵심 학습]

- 4회차: Spark SQL Silver 중복 제거·MERGE
- 5회차: dbt Gold 마트·품질 테스트
- 6회차: 과거 데이터 수정·삭제 소급 정정

[프로젝트 진행 방식]

내가 설계한 도메인 테이블과 지표를 파이프라인에 실제 투입·구현

STEP 4 — 7~8회차

성능 튜닝 & 운영 점검

[핵심 학습]

- 7회차: Iceberg 작은 파일 (rewrite_data_files)·파티션·쿼리 튜닝
- 8회차: Airflow 연동·장애 복구 점검·최종 리뷰

[프로젝트 진행 방식]

Iceberg의 단점(Small Files)을 직접 해결하는 전후 성능 비교 벤치마크 완성 (발표 별도)

지난 시간의 결과에서 출발합니다

4회차 Silver 결과

refund-r1 한 행
amount 30000 · is_deleted = true
LSN 300 · offset 12

오늘의 질문

결제 100,000원인 이 주문의
순결제액은 얼마일까요?
(답은 18장에서 확인)

Silver는 현재 상태까지만 알려 줍니다 · 무엇을 더하고 뺄지는 Gold에서 정합니다

정산 담당자는 무엇을 보고 싶을까

먼저 물을 것	공통 예제의 답
누가 쓰나요?	정산 담당자
어떤 판단에 쓰나요?	주문일별로 실제로 남은 결제액 확인
얼마나 빨리 봐야 하나요?	30분쯤 늦은 숫자도 괜찮음 (설계 가정)
어떤 단위로 보나요?	주문 한 건, 그리고 주문일 하루

갱신 주기와 집계 단위는 쓰는 사람의 요구에서 정합니다

오늘 확인할 다섯 가지

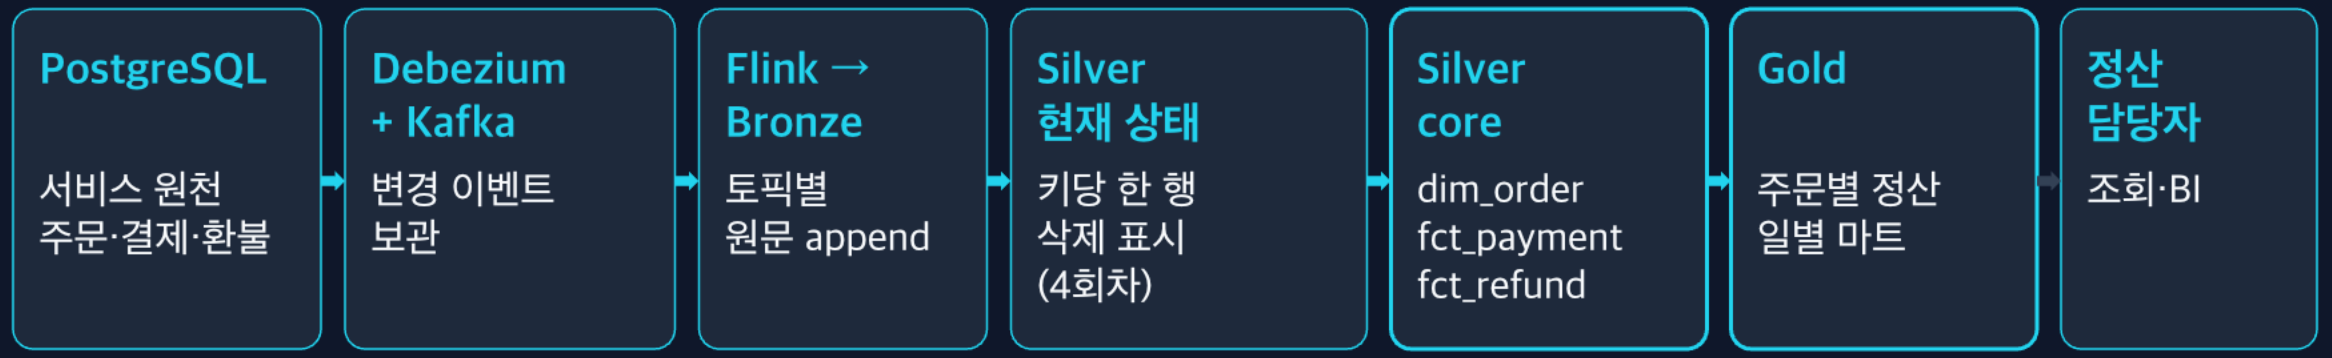
확인할 것	오늘의 기준
① 쓰임·지표 정의	정산 담당자·30분 가정 / 성공 결제 – 성공 환불(철회 제외)
② 층과 단위	Silver core: 결제·환불·주문 1건 / Gold: 주문 1건·하루
③ 집계 대상·조인	삭제 제외는 Silver core · status는 Gold / 먼저 집계
④ 데이터 테스트	키·관계·금액 규칙·기댓값
⑤ 갱신 주기·약속	table 전체 교체 주기 / 설명·소유·열 계약

13장의 설계 순서와 같은 번호로 진행합니다

Silver core를 거쳐 Gold로

지난 회차까지의 흐름

오늘: dbt로 Silver core와 Gold 만들기



이번 회차의 방식

저장소 dbt 코드와 공통 환경에서 확인한 출력을 함께 읽기
수업 중 새 실행은 하지 않음

실행 역할

pipeline.py: Bronze → Silver 현재 상태
dbt + Spark: Silver core → Gold

Silver를 두 단계로 나눕니다 · 공통 fact·dim은 Silver core에, 보는 사람에 맞춘 표는 Gold에

fact·dim은 어느 층에 둘까

	A. Gold 중심	B. Silver 중심 (이 과정)
Silver	정제·중복 제거, 원천 모양 유지	현재 상태 + 공통 fact·dim (가장 작은 단위)
Gold	fact·dim(star schema) + 마트	보는 사람에 맞춘 넓은 표·집계 마트
잘 맞는 곳	도메인 하나, BI가 직접 조인	여러 마트가 같은 규칙을 재사용
치르는 비용	마트마다 같은 규칙을 반복	Silver 모델 증가, 공통 규칙 합의

Databricks 문서는 dimensional model을 Gold에 둡니다 · 이 과정은 재사용을 위해 B를 고릅니다

dbt는 무엇이고 왜 쓰나

dbt가 대신 해 주는 일	공통 예제에서는
SELECT만 쓰면 테이블·뷰 생성(DDL)	모델 파일에 CREATE 없음 · 모두 table
ref·source로 실행 순서와 계보	Silver core를 먼저, Gold를 나중에
테스트·설명을 SQL 옆에	데이터 테스트 15개 · 모델 설명
Git 리뷰·CI 흐름을 그대로	SQL과 테스트를 한 PR로 리뷰 (29장)
증분 모델로 바뀐 부분만 반영	6회차 주제 · 지금은 매번 전체 교체

dbt는 이미 들어온 데이터를 엔진 안에서 바꾸는 변환(T) 도구이고 계산은 Spark가 합니다

주의할 점과 dbt를 고르는 기준

주의할 점

엔진·스케줄러·수집 도구 아님
실제 SQL은 컴파일 결과로
테스트는 만든 뒤에 검사
재실행 결과는 모델이 정함

dbt가 맞을 때

SQL로 쓰는 배치 변환
모델이 여럿이고 서로 의존
테스트·설명·리뷰가 필요
여러 사람이 같이 고침

다른 도구가 나을 때

모델 2~3개: SQL 스크립트
절차 로직·튜닝: PySpark
초 단위 실시간: Flink SQL
엔진 어댑터가 미성숙

이 저장소: 수집은 Flink, Silver 현재 상태는 Spark SQL 스크립트, Silver core와 Gold는 dbt

프로젝트 파일이 맡는 일

파일	맡는 일	우리 프로젝트
dbt_project.yml	기본 설정	모두 table·iceberg / 층마다 폴더 = 스키마
profiles.yml + macros/	어디에 쓰나	Spark Thrift · 폴더 스키마 이름 그대로
models/silver/*.sql	Silver core 모델	dim_order, fct_payment, fct_refund
models/gold/*.sql	Gold 모델	mart_order_settlement, mart_daily_settlement
sources.yml · _층__models.yml · tests/	원천 / 설명·테스트	원천 3개 · 테스트 15개

모델 파일에는 CREATE 문이 없고 어디에 무엇으로 만들지는 설정이 정합니다

source와 ref가 의존성을 만듭니다

source()

Silver 현재 상태를
원천으로 선언

→

ref()

다른 모델을 참조
실행 순서·계보가 생김

→

컴파일

실제 테이블 이름으로
바뀐 SQL을 실행

```
-- dim_order (Silver core)에 쓴 것
from {{ source('silver','orders') }}      -- 컴파일: from silver.orders
-- mart_order_settlement (Gold)에 쓴 것
from {{ ref('fct_payment') }}          -- 컴파일: from silver.fct_payment
from {{ ref('dim_order') }} o          -- 컴파일: from silver.dim_order o
```

ref·source로 연결해야 dbt가 실행 순서와 계보(lineage)를 압니다

dbt build는 모델마다 실행 후 테스트

dbt run을 다 끝낸 뒤 dbt test를 하는 것과 다릅니다
의존 순서대로 '모델 실행 → 그 모델의 테스트'를 이어 갑니다

① 읽기·컴파일

프로젝트 파싱
ref·source 해석

② Silver core

dim·fct 생성
바로 키·관계 테스트

③ 실패하면 멈춤

Silver core 테스트 실패 시
하류 Gold는 SKIP

④ Gold

주문·일별 마트 생성
Gold 테스트

Silver core가 막히면 Gold는 SKIP되고 이미 바뀐 Silver core와 시점이 어긋나 알림이 필요합니다

설계 순서와 아홉 가지 질문

묶음	물을 것	공통 예제
① 쓰임·정의	누가·무슨 판단·얼마나 자주 / 무엇을 더하고 빼나	정산 담당자·30분 / 순결제액
② 층과 단위	가장 작은 단위는 / 보는 단위는 / 어느 시간대 날짜	결제·환불 1건 / 주문·하루 / 서울
③ 집계 대상·조인	어떤 행을 세나 / 부풀지 않게 묶나	삭제 제외·success / 먼저 집계
④ 테스트	어떻게 틀릴 수 있고 무엇으로 막나	키·관계·규칙·기댓값
⑤ 갱신·관리	얼마나 자주 다시 만드나 / 누가 무엇을 약속	table 30분 / 설명·소유·계약

도메인이 바뀌어도 같은 순서로 묻고 답마다 근거를 함께 적습니다

지표를 먼저 정의합니다

지표	정의	아닌 것
결제액 paid	주문의 성공 결제 합 (삭제 표시 제외)	실패·취소된 결제
환불액 refunded	성공 환불 합 (삭제 표시 제외, 연결된 결제도 같은 조건)	철회된 환불
순결제액 net_paid	paid – refunded, 주문일 기준	회계 매출, 환불일 기준 정산

정의에 '아닌 것'까지 적습니다 · _gold__models.yml: not accounting revenue

한 행은 무엇인가 (층별 단위)

Silver core

fct_payment: 결제 1건
fct_refund: 환불 1건
dim_order: 주문 1건

Gold 주문 마트

주문 1건 = 1행
결제·환불을 주문별 합
주문 단위 검증·추적

Gold 일별 마트

주문일 하루 = 1행
주문 마트를 다시 모음
대시보드용

가장 작은 단위를 Silver core에 두면 다른 마트도 같은 사실에서 다시 묶을 수 있습니다

날짜와 시간대

저장된 값

ordered_at TIMESTAMP
Spark 세션 TZ = UTC
(공통 환경 설정)

변환 (dim_order)

UTC 시각을
서울 벽시계 시각으로
Silver core에서 한 번

주의

세션 TZ가 다르면
결과가 달라짐
내 환경부터 확인

```
-- dim_order (Silver core)
to_date(from_utc_timestamp(ordered_at,'Asia/Seoul')) order_date
-- 2026-10-30 15:30 (UTC) → 2026-10-31 00:30 (서울) → 2026-10-31
```

주문일은 dim_order에서 한 번만 정하고 Gold의 모든 표가 그 날짜를 씁니다

어떤 행을 셀까

조건	어디서	왜
not is_deleted (주문·결제·환불)	Silver core	철회·삭제된 건은 공통 사실이 아님
환불 → 결제 → 주문 키 연결	Silver core fct_refund	모든 마트가 같은 주문 키
결제 status = 'success'	Gold 주문 마트	정산 지표의 정의
환불·연결 결제 모두 success	Gold 주문 마트	성공 결제에 대한 성공 환불만

공통 사실의 조건은 Silver core에, 지표의 정의는 Gold에 둡니다

3장의 답: 철회된 환불의 순결제액

Silver 현재 상태

결제 100,000원 · success
환불 30,000원 → 철회
is_deleted = true

Silver core → Gold

fct_refund에 이 환불 없음
refunded 0
net_paid 100,000

공통 검증 스크립트(verify.py)도 이 경우 100,000원을 기댓값으로 확인합니다

조인이 숫자를 부풀리는 경우

먼저 조인하고 합하면

결제 1행 × 환불 2행 → 2행
sum(결제) = 200,000 ✗
sum(환불) = 30,000

먼저 집계하고 조인하면

결제 합 100,000 (주문당 1행)
환불 합 30,000 (주문당 1행)
순결제액 70,000 ✓

1:N 조인 뒤에 합하면 1쪽 값이 N번 더해집니다 · 손 계산 예시 (환불 10,000 + 20,000)

Silver core 읽기: 공통 규칙을 한 번만

```
-- dim_order: 주문 1건 = 1행, 서울 기준 주문일
select order_id, ordered_at,
       to_date(from_utc_timestamp(ordered_at,'Asia/Seoul')) order_date, status
from {{ source('silver','orders') }} where not is_deleted

-- fct_payment: 결제 1건 = 1행
select payment_id, order_id, amount, status
from {{ source('silver','payments') }} where not is_deleted

-- fct_refund: 환불 1건 = 1행, 결제를 거쳐 주문 키
select r.refund_id, r.payment_id, p.order_id, r.amount, r.status,
       p.status payment_status
from {{ source('silver','refunds') }} r
left join {{ ref('fct_payment') }} p on r.payment_id=p.payment_id
where not r.is_deleted
```

세 모델 모두 삭제 제외 · 집계 없음 · 가장 작은 단위 · 저장소 SQL에 설명 주석만 더했습니다

Gold 읽기: 먼저 집계하고 주문에 붙이기

```
with payments as (   -- 결제: 주문별 합
  select order_id, sum(amount) paid from {{ ref('fct_payment') }}
  where status='success' group by order_id
), refunds as (      -- 환불: 주문별 합
  select order_id, sum(amount) refunded from {{ ref('fct_refund') }}
  where status='success' and payment_status='success' group by order_id
)
select o.order_id, o.order_date,
       coalesce(p.paid,0) paid, coalesce(r.refunded,0) refunded,
       coalesce(p.paid,0)-coalesce(r.refunded,0) net_paid,
       current_timestamp() mart_built_at
from {{ ref('dim_order') }} o
left join payments p on o.order_id=p.order_id
left join refunds r on o.order_id=r.order_id
-- 일별 마트: select order_date, count(*) … from {{ ref('mart_order_settlement') }} group by order_date
```

두 CTE 모두 주문당 한 행 · left join + coalesce로 결제·환불이 없는 주문도 0으로 남습니다

데이터 테스트의 종류

generic 테스트

unique · not_null
accepted_values
relationships
YAML 한 줄로

singular 테스트

규칙을 어긴 행을
반환하는 SELECT 파일
0행이면 통과

unit 테스트

고정 입력으로
모델 로직 확인
우리 조합: 실행 오류

데이터 테스트는 지금 만들어진 테이블의 데이터를 검사합니다

우리 프로젝트의 테스트 열다섯 개

테스트	보장하는 것	보장하지 못하는 것
Silver core 키 unique·not_null (6)	결제·환불·주문 1건당 한 행	금액이 맞는지
relationships (2)	결제→주문, 환불→결제 키가 실제로 있음	status가 맞는지
order_date not_null (2)	dim_order·주문 마트 날짜가 비지 않음	시간대가 맞는지
Gold 키 unique·not_null (4)	주문당·하루당 한 행	합계가 맞는지
settlement_balance (1)	net = paid − refunded, ≥ 0	부푼 금액, 초과 환불

실측(11/1): dbt build PASS=20 (모델 5 + 테스트 15) · 통과는 정의한 조건까지만 보장합니다

지금 테스트로 잡을 수 있을까

틀릴 수 있는 방식	지금 15개로?	추가할 테스트 (설계)
조인 fan-out으로 결제액 2배	못 잡음	환불 2건+ 검증 입력 기댓값, 결제 합계 비교
없는 결제를 가리키는 환불	잡음 (relationships)	이미 있음: fct_refund → fct_payment
예상 밖 status 값	못 잡음	Silver core accepted_values: status
환불이 결제보다 큼	못 잡음	singular: refunded > paid

'어떻게 틀릴 수 있나'를 먼저 적고 하나씩 막습니다 · 오른쪽 열의 추가안은 실행 전 설계입니다

테스트 결과 읽기

명령

dbt build
모델 5 + 테스트 15

이름 규칙

테스트_모델_열
예: unique_fct_payment_payment_id

실패하면

실패 행 수 확인
컴파일된 SQL을
직접 실행해 원인 행

```
Found 5 models, 15 data tests, 3 sources, 516 macros
7 of 20 PASS relationships_fct_payment_order_id__order_id__ref_dim_order_
16 of 20 PASS settlement_balance
Done. PASS=20 WARN=0 ERROR=0 SKIP=0
```

실측(11/1) · 실패하면 target/compiled의 테스트 SQL로 원인 행을 찾습니다

table 모델은 매번 다시 씁니다

① create or replace

dbt-spark가 Iceberg에
테이블을 통째로 교체
(RTAS)

② 새 snapshot

최근 5개 모두 overwrite
parent_id 없음
(10/31 관찰)

③ 쌓이는 이력

주문 테이블 snapshot 902개
(10/31, 이전 이름)
전체 교체가 반복됨

읽는 쪽은 교체 전 또는 교체 후 한 상태만 봅니다 · 오래된 snapshot 정리는 7회차

얼마나 자주 다시 만들까

선택	신선도	비용·주의
DAG를 켜면: 5분마다 Silver→dbt build	최대 5분 + 실행 시간	하루 최대 288번 전체 교체
제안: Silver 5분 / Gold 30분 분리	30분 + 실행 시간 + Silver 지연	하루 48번 · 신선도 요구와 다시 대조
더 빨라야 한다면	분 단위	증분 모델·다른 실행 방식 검토

주기는 4장의 '얼마나 빨리 봐야 하나'에서 정합니다 · 분리는 설계안입니다

증분 모델 예고

table (지금)

매번 전체를 다시 계산
단순하고 결과가 분명
데이터가 크면 비쌈

incremental (6회차)

바뀐 부분만 반영
'바뀐 행'을 찾는 기준 필요
삭제·늦은 정정까지 처리

6회차 질문: 바뀐 것만 반영하면서도 과거 정정과 삭제를 놓치지 않으려면?

협업을 위한 약속 ① 설명·계보·소유

설명 (description)

무엇인지, 무엇이 아닌지
예: not accounting revenue

계보 (lineage)

source → ref로 연결
dbt ls·docs로 확인

소유 (owner)

누가 답하나
Silver core·Gold 소유 구분
groups·meta로 표시

변환 SQL과 그 설명·테스트를 같은 저장소에서 함께 리뷰하고 고칩니다

협업을 위한 약속 ② 모델 계약

약속하는 것

열 이름·타입
빌드 전에 확인

→

우리 조합의 한계

Spark에서 constraints
강제되지 않음
(NOT_ENFORCED)

→

그래서

계약은 열 모양을
데이터 내용은
테스트가 확인

```
models:
  - name: mart_order_settlement
    config: {contract: {enforced: true}}
    columns: [{name: order_id, data_type: string},
              {name: net_paid, data_type: bigint}, ...]
```

설계 예시 · 저장소에 적용·실행하지 않았습니다 (동작은 설치 코드로 확인)

내 테이블로 Silver core와 Gold 설계하기 (약 10분)

묶음	내 도메인으로 적을 것
① 쓰임·정의	누가·무슨 판단·얼마나 자주 / 지표 하나와 '아닌 것'
② Silver core	fact 한두 개와 dim 하나 / 가장 작은 단위·공통 키·날짜
③ Gold	보는 단위 / 셀 행의 조건 / 부풀지 않는 조인 순서
④ 테스트	키·관계 테스트와 틀릴 수 있는 방식 하나
⑤ 갱신·관리	다시 만드는 주기 / 설명 한 줄·소유자

진행: 예시 2분 → ①② 3분 → ③④⑤ 3분 → 채팅 공유 2분

남길 결과와 다음 회차

오늘 남길 것

Silver core의 fact·dim·단위
지표 정의와 '아닌 것'
조인 순서·테스트

확인한 사실

dbt build: Silver core → Gold
table은 매번 전체 교체
Spark 계약은 모양까지

6회차

증분 모델
수정·삭제·소급 정정
다시 계산해도 같은 답인가

다음 시간: 바뀐 것만 반영하면서도 과거 정정과 삭제를 놓치지 않는 법